전처리 · 유사도/거리

A. 데이터 전처리 + 유사도·거리 (Ch.2 Data)

A1. 속성 척도 (Attribute Types)

척도	성질	허용 연산·통계	예
명목 (Nominal)	구별 $=, \neq$	최빈값(mode), 엔트로피, χ^2	ID, 우편번호, 눈 색
순서 (Ordinal)	+ 순서 $<, >$	중앙값, 백분위, 순위상관	성적 A~F, 만족도
구간 (Interval)	+ 차이 $+, -$	평균, 표준편차, Pearson 상관	섭씨, 날짜
비율 (Ratio)	+ 비율 $\times, \div$ (절대 0)	기하·조화평균, 변동계수	켈빈, 길이, 나이, 개수

- 명목·순서 = 범주형(categorical/qualitative), 구간·비율 = 수치형(numeric/quantitative)
- 허용 변환: 명목=일대일 치환, 순서=순서 보존 단조 변환, 구간 $x' = ax + b$, 비율 $x' = ax$
- 이산(discrete): 유한·가산 값, 이진(binary)은 특수형 / 연속(continuous): 실수값
- 비대칭 속성(asymmetric): 0이 아닌 값(존재)만 의미, 예: 장바구니·문서 단어 → 0-0 일치 무시

A2. 데이터 품질 (Data Quality)

- 잡음(noise): 측정값의 무작위 왜곡 / 인공물(artifact): 결정적 왜곡
- 이상치(outlier): 다른 객체와 동떨어진 값, 때로 분석 대상 자체(사기 탐지)
- 결측값(missing): 객체 제거, 추정(평균·보간), 분석 시 무시
- 중복(duplicate): 동일 객체 여러 레코드, 병합 시 발생 → 중복 제거(deduplication)
- 정밀도(precision, 반복 측정 근접성) vs 편향(bias, 참값과의 체계적 차이) vs 정확도(accuracy)

A3. 전처리 기법 (Preprocessing)

기법	한 줄 요약
집계 (Aggregation)	여러 객체를 하나로 합침, 데이터 축소·척도 변경·변동성 감소
샘플링 (Sampling)	대표성 있는 부분집합으로 처리비용 절감
차원 축소 (Dimensionality Reduction)	PCA, SVD 등 선형대수 기법으로 새 축 생성
특성 부분집합 선택 (Feature Subset Selection)	중복·무관 속성 제거, 내장(embedded)·필터(filter)·래퍼(wrapper)
특성 생성 (Feature Creation)	특성 추출, 새 공간으로 사상(푸리에·웨이블릿), 특성 구성
이산화·이진화 (Discretization/Binarization)	연속→범주, 범주→이진 변수
변수 변환 (Variable Transformation)	단순 함수($\log x$, $\sqrt{x}$, $1/x$), 정규화·표준화

- 샘플링: 단순 무작위(SRS) 비복원(without replacement)/복원(with replacement, 같은 객체 재선택 가능), 층화(stratified, 그룹별 추출 → 희귀 클래스 보존), 점진(progressive, 작은 표본에서 시작해 정확도 수렴 시까지 확대)
- 차원의 저주(curse of dimensionality): 차원 증가 시 데이터가 희소, 점 간 거리 차이가 작아져 밀도·거리 개념 약화 → 군집·분류 성능 저하
- PCA: 분산 최대 방향의 서로 직교인 새 축(주성분)으로 선형 사상, 상위 성분만 유지
- 이산화(비지도): 등간격(equal width, 구간 폭 동일, 이상치에 민감), 등빈도(equal frequency/depth, 구간별 개수 동일), K-means 군집 기반
- 이산화(지도): 엔트로피 기반, 클래스 순도 최대 분할점 선택 → 최악(최고 엔트로피) 구간 반복 분할, $e_i = -\sum_j p_{ij} \log_2 p_{ij}$, 전체 $e = \sum_i w_i e_i$
- 표준화(z-score): $x' = \frac{x - \bar{x}}{s_x}$ (평균 0, 표준편차 1), 이상치에 강건하려면 중앙값·절대편차 사용
- 최소-최대 정규화(min-max): $x' = \frac{x - \min}{\max - \min} \in [0, 1]$

A4. 유사도·거리 기본

- 유사도(similarity): 비슷할수록 큼, 보통 $[0, 1]$ / 비유사도(dissimilarity): 비슷할수록 작음, 최소 0 / 둘을 합쳐 근접도(proximity)

속성	비유사도 d	유사도 s
명목	$x = y$면 0, 아니면 1	$x = y$면 1, 아니면 0
순서 (값을 $0..n-1$로 사상)	$\lvert x - y \rvert / (n - 1)$	$1 - d$
구간·비율	$\lvert x - y \rvert$	$-d$, $\frac{1}{1+d}$, e^{-d}, $1 - \frac{d - \min_d}{\max_d - \min_d}$

- 거리→유사도 변환: $s = 1 - d$ ($d \in [0, 1]$), $s = \frac{1}{1+d}$ ($d = 0, 1, 10, 100 \rightarrow s = 1, 0.5, 0.09, 0.01$, 비선형), $s = e^{-d}$, min-max 사상

A5. 민코프스키 계열 (Minkowski)

- $d(\mathbf{x}, \mathbf{y}) = \left(\sum_{k=1}^{n} |x_k - y_k|^r\right)^{1/r}$, r(파라미터)과 n(차원 수) 혼동 금지
- $r = 1$ 맨해튼(Manhattan, city block, L_1): 이진 벡터면 해밍 거리(Hamming, 다른 비트 수)
- $r = 2$ 유클리드(Euclidean, L_2): 척도가 다르면 표준화 필수
- $r \to \infty$ 상한(supremum, $L_{\max}$, L_∞): $\max_k |x_k - y_k|$
- 슬라이드 예: p1(0,2), p2(2,0), p3(3,1), p4(5,1)

쌍	L_1	L_2	L_∞
p1-p2	4	2.828	2
p1-p3	4	3.162	3
p1-p4	6	5.099	5
p2-p3	2	1.414	1
p2-p4	4	3.162	3
p3-p4	2	2	2

- 계산 예 p1-p4: 차이 (5,1) → $L_1 = 5 + 1 = 6$, $L_2 = \sqrt{25 + 1} = 5.099$, $L_\infty = \max(5, 1) = 5$

A6. 마할라노비스 (Mahalanobis)

- $\text{mahal}(\mathbf{x}, \mathbf{y}) = (\mathbf{x} - \mathbf{y}) \Sigma^{-1} (\mathbf{x} - \mathbf{y})^T$, Σ = 데이터 공분산 행렬, $\Sigma_{jk} = \frac{1}{n-1} \sum_i (X_{ij} - \bar{X}_j)(X_{ik} - \bar{X}_k)$
- 의미: 속성 간 상관·척도 차이 보정, 분포의 긴 축 방향 거리는 짧게 → 타원형 분포에 적합, $\Sigma = I$면 유클리드 제곱과 동일
- 슬라이드 예: $\Sigma = \begin{pmatrix} 0.3 & 0.2 \\ 0.2 & 0.3 \end{pmatrix}$, $\Sigma^{-1} = \begin{pmatrix} 6 & -4 \\ -4 & 6 \end{pmatrix}$, A(0.5,0.5), B(0,1), C(1.5,1.5)
- A-B=$(0.5, -0.5)$: $6(0.25) + 6(0.25) - 8(-0.25) = 5$ → Mahal(A,B)=5
- A-C=$(-1, -1)$: $6 + 6 - 8 = 4$ → Mahal(A,C)=4 (유클리드로는 C가 더 멀지만 상관 방향이라 더 가까움)

A7. 거리·유사도의 성질

- 거리(metric) 3성질: ① 양수성(positivity) $d \geq 0$, $d = 0 \iff x = y$ ② 대칭성(symmetry) $d(x, y) = d(y, x)$ ③ 삼각부등식(triangle inequality) $d(x, z) \leq d(x, y) + d(y, z)$
- 유사도 성질: $s = 1$(최대) $\iff x = y$, 대칭성 / 삼각부등식 일반적으로 불성립
- 비거리 예: 집합 차 $d(A, B) = |A - B|$(비대칭), 시간 차 $d = y - x$ 음수 가능

A8. 이진 벡터 유사도: SMC vs Jaccard

- $M_{01}, M_{10}, M_{00}, M_{11}$ = (x,y) 값 조합별 속성 개수
- SMC(Simple Matching Coefficient) = $\frac{M_{11} + M_{00}}{M_{01} + M_{10} + M_{11} + M_{00}}$: 0-0 일치 포함, 대칭 이진 속성(성별 등)
- Jaccard $J = \frac{M_{11}}{M_{01} + M_{10} + M_{11}}$: 0-0 일치 무시, 희소 비대칭 이진 데이터(장바구니·문서), 범위 $[0, 1]$
- 슬라이드 예: x=1000000000, y=0000001001 → $M_{01} = 2, M_{10} = 1, M_{00} = 7, M_{11} = 0$
- SMC $= (0 + 7)/(2 + 1 + 0 + 7) = 0.7$
- $J = 0/(2 + 1 + 0) = 0$ → 희소 데이터에서 SMC는 거의 모든 쌍을 유사하다고 판정

A9. 코사인 (Cosine)

- $\cos(\mathbf{x}, \mathbf{y}) = \frac{\mathbf{x} \cdot \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}$, 범위 $[-1, 1]$, 음이 아닌 데이터면 $[0, 1]$
- 특징: 벡터 길이 무시, 각도만 비교, 0-0 일치 무시 → 문서·단어 빈도 벡터(희소, 비대칭)에 표준
- 슬라이드 예: d1=(3,2,0,5,0,0,0,2,0,0), d2=(1,0,0,0,0,0,0,1,0,2)
- $d1 \cdot d2 = 3 \cdot 1 + 2 \cdot 1 = 5$, $\|d1\| = \sqrt{9 + 4 + 25 + 4} = \sqrt{42} = 6.481$, $\|d2\| = \sqrt{1 + 1 + 4} = \sqrt{6} = 2.449$
- $\cos = 5/(6.481 \times 2.449) = 0.3150$ (슬라이드 원문의 2.245는 오타, $\sqrt{6} = 2.449$)

A10. 확장 Jaccard (Tanimoto)

- $EJ(\mathbf{x}, \mathbf{y}) = \frac{\mathbf{x} \cdot \mathbf{y}}{\|\mathbf{x}\|^2 + \|\mathbf{y}\|^2 - \mathbf{x} \cdot \mathbf{y}}$: 연속·빈도 속성용 Jaccard, 이진이면 Jaccard와 동일
- 위 d1,d2 적용: $5/(42 + 6 - 5) = 5/43 = 0.116$

A11. 피어슨 상관 (Pearson Correlation)

- $\text{corr}(\mathbf{x}, \mathbf{y}) = \frac{s_{xy}}{s_x s_y}$, $s_{xy} = \frac{1}{n-1} \sum_k (x_k - \bar{x})(y_k - \bar{y})$ = 각 벡터 표준화 후 내적/$(n-1)$
- 범위 $[-1, 1]$: 1 완전 양의 선형, −1 완전 음의 선형, 0 선형관계 없음
- 비선형 관계 못 잡음: $x = (-3, -2, -1, 0, 1, 2, 3)$, $y = x^2 = (9, 4, 1, 0, 1, 4, 9)$ → corr=0 (완전한 함수관계인데도)
- 완전 상관 예: $x = (-3, 6, 0, 3, -6)$, $y = (1, -2, 0, -1, 2)$ → $y = -x/3$ → corr=−1

A12. 척도 비교 (불변성)

	스케일 $y = ay$	평행이동 $y = y + b$
코사인	불변	변함
상관	불변	불변
유클리드	변함	변함

- 예: x=(1,2,4,3,0,0,0), y=(1,2,3,4,0,0,0) → cos 0.9667, corr 0.9364, L_2 1.4142 / 2y: 0.9667, 0.9364, 5.8310 / $y + 5$: 0.8259, 0.9364, 13.3041
- 상관 = 평균 중심화한 벡터의 코사인, 데이터 평균 0이면 코사인과 같음

A13. 혼합 속성 결합 (Heterogeneous)

- 속성 k별 유사도 $s_k \in [0, 1]$ 계산, 지시변수 $\delta_k = 0$(비대칭 속성이면서 둘 다 0, 또는 결측), 아니면 1
- $\text{sim}(\mathbf{x}, \mathbf{y}) = \frac{\sum_k \delta_k s_k}{\sum_k \delta_k}$
- 가중치(weights) w_k, $\sum w_k = 1$: $\text{sim} = \frac{\sum_k w_k \delta_k s_k}{\sum_k \delta_k}$, 거리형 $d = \left(\sum_k w_k |x_k - y_k|^r\right)^{1/r}$

A14. 척도 선택 요령

- 연속·밀집 데이터, 척도 동일 → 유클리드(L_2), 척도 상이 → 표준화 후 유클리드, 상관된 속성 → 마할라노비스
- 격자형 이동·이상치 완화 → L_1, 최대 편차만 중요 → L_∞
- 희소 비대칭 이진 → Jaccard / 대칭 이진 → SMC
- 문서·빈도 벡터(크기 무관) → 코사인, 빈도 크기도 반영 → Tanimoto
- 시계열 등 모양(패턴)만 비교, 평균·스케일 차이 무시 → 상관
- 속성 유형 혼재 → 속성별 유사도 후 가중 결합

시험 직전 체크

- SMC는 0-0 일치 포함, Jaccard는 분모에서 M_{00} 제외 → 희소 데이터에서 SMC 과대
- Minkowski의 r은 차원 수 n이 아님, L_∞는 합이 아닌 최대 차이
- 코사인은 평행이동에 변함, 상관은 스케일·평행이동 모두 불변, 유클리드는 둘 다 변함
- corr=0은 선형관계 없음일 뿐 독립 아님 ($y = x^2$ 예)
- 마할라노비스 슬라이드 값(5, 4)은 제곱근 없는 형태, Σ^{-1} 사용

연관규칙분석

C. 연관규칙분석 (Association Analysis) — Tan 2판 5장

C1. 기본 개념·데이터

Table 5.1 장바구니 거래 (market basket transactions)

TID	Items
1	{Bread, Milk}
2	{Bread, Diapers, Beer, Eggs}
3	{Milk, Diapers, Beer, Cola}
4	{Bread, Milk, Diapers, Beer}
5	{Bread, Milk, Diapers, Cola}

- 항목집합(itemset): 항목 모음, k개면 k-itemset. 거래 폭(transaction width) = 거래 내 항목 수
- 지지도 개수(support count) $\sigma(X) = |\{t_i \mid X \subseteq t_i\}|$, 지지도(support) $s(X) = \sigma(X)/N$
- 빈발 항목집합(frequent itemset): $s(X) \geq minsup$
- 연관규칙(association rule) $X \to Y$, $X \cap Y = \emptyset$ (X: 전건 antecedent, Y: 후건 consequent)
- $s(X \to Y) = \frac{\sigma(X \cup Y)}{N}$ (규칙 적용 빈도), $c(X \to Y) = \frac{\sigma(X \cup Y)}{\sigma(X)}$ (신뢰성, $\approx P(Y|X)$)
- **예 5.1 {Milk, Diapers}→{Beer}**: σ(Milk,Diapers,Beer)=2 (TID 3,4) → $s = 2/5 = 0.4$. σ(Milk,Diapers)=3 (TID 3,4,5) → $c = 2/3 = 0.67$. 참고 lift $= 0.67/s(\text{Beer}) = 0.67/0.6 \approx 1.11$
- 목표: $s \geq minsup$, $c \geq minconf$ 규칙 전부 탐색. 연관 ≠ 인과(causality)

C2. Brute-force 복잡도·2단계 전략

- 가능한 규칙 수 $R = 3^d - 2^{d+1} + 1$. Table 5.1($d = 6$): $3^6 - 2^7 + 1 = 602$개, minsup 20%·minconf 50%면 80% 이상 폐기 → 낭비
- 가능한 항목집합 2^d (공집합 제외 $2^d - 1$). 후보 전수 대조 $O(NMw)$, $M = 2^d$, w=최대 거래 폭
- **2단계**: ① 빈발 항목집합 생성(frequent itemset generation, 비용 대부분) → ② 규칙 생성(rule generation, 고신뢰 규칙 추출)
- 같은 항목집합의 규칙은 support 동일 → 두 조건 분리 가능

C3. Apriori 원리

- **정리 5.1**: 빈발 항목집합의 모든 부분집합도 빈발. 대우: 비빈발 집합의 모든 상위집합(superset)도 비빈발 → 격자(lattice)에서 서브그래프 통째로 가지치기(support-based pruning)
- **anti-monotone 성질**: $\forall X \subseteq Y: \ s(X) \geq s(Y)$ (집합 커지면 support 증가 불가)

C4. Apriori 알고리즘 (Alg. 5.1)

1. $k = 1$, $F_1 = \{i \mid \sigma(\{i\}) \geq N \cdot minsup\}$
2. 반복: $k{+}{+}$ → C_k=candidate-gen(F_{k-1}) → candidate-prune → 거래마다 subset(C_k, t)로 포함 후보 $\sigma{+}1$ → $F_k = \{c \mid \sigma(c) \geq N \cdot minsup\}$
3. $F_k = \emptyset$이면 종료, 결과 $\bigcup F_k$. 수준별(level-wise) 탐색, 최대 $k_{max} + 1$회 스캔

후보 생성 방법	내용
Brute-force	k-항목집합 $\binom{d}{k}$개 모두 후보, 가지치기 비용 과다
$F_{k-1} \times F_1$	빈발 (k-1)-집합에 빈발 1-항목 추가. 완전하나 중복·불필요 후보 발생, 사전순(lexicographic) 정렬로 중복 방지
$F_{k-1} \times F_{k-1}$ (Apriori 채택)	사전순 정렬 후 **앞 k-2개 항목 동일**한 두 (k-1)-집합 병합. 예: {Bread,Diapers}+{Bread,Milk} →{Bread,Diapers,Milk}

- 후보 가지치기(candidate pruning): 후보의 (k-1)-부분집합 중 하나라도 비빈발이면 제거
- support counting: hash tree에 후보 분산, 거래 부분집합을 해시해 같은 버킷 후보와만 비교

교재 예 (Table 5.1, minsup 60% = count 3)

- 1-항목: Bread 4, Milk 4, Diapers 4, Beer 3 빈발 / Cola 2, Eggs 1 제거
- 2-항목 후보 $\binom{4}{2} = 6$: {Beer,Bread}=2, {Beer,Milk}=2 제거, 나머지 4개 빈발(각 3)
- 3-항목: 가지치기 없으면 $\binom{6}{3} = 20$, Apriori로 {Bread,Diapers,Milk} 1개만 남으나 σ=2로 비빈발
- 후보 총수: brute-force $\binom{6}{1} + \binom{6}{2} + \binom{6}{3} = 6 + 15 + 20 = 41$ vs Apriori $\binom{6}{1} + \binom{4}{2} + 1 = 6 + 6 + 1 = 13$ → **68% 감소**

C5. 계산 복잡도 영향 요인

요인	영향
minsup 낮춤	빈발 집합 증가, 최대 크기 증가 → 후보·스캔 횟수 증가
항목 수 (dimensionality) d	support count 저장 공간 증가, 빈발 항목 많으면 후보 폭증
거래 수 N	반복 스캔이라 실행시간 증가
평균 거래 폭	최대 빈발 크기 증가, 거래당 부분집합 증가 → hash tree 탐색 증가

C6. 규칙 생성

- 빈발 k-집합 Y 하나에서 최대 $2^k - 2$개 규칙 ($X \to Y - X$). support는 이미 충족, confidence 계산에 추가 스캔 불필요 (부분집합 σ 이미 계산)
- confidence는 일반적으로 anti-monotone 아님. 단 **같은 항목집합 내에서 성립 (정리 5.2)**: $\tilde{X} \subset X$면 $c(\tilde{X} \to Y - \tilde{X}) = \sigma(Y)/\sigma(\tilde{X}) \leq \sigma(Y)/\sigma(X) = c(X \to Y - X)$
- 후건 항목 늘수록 c 감소. 예: $\{bcd\} \to \{a\}$ 저신뢰면 후건에 a 포함 규칙($\{cd\} \to \{ab\}$ 등) 모두 제거
- Apriori 규칙 생성(Alg. 5.2/5.3 ap-genrules): 후건 1개짜리 고신뢰 규칙부터 시작, 후건 병합으로 다음 수준 후보 생성(예: $\{acd\} \to \{b\}$, $\{abd\} \to \{c\}$ → $\{ad\} \to \{bc\}$)

C7. 압축 표현 (Compact Representation)

- **최대 빈발(maximal frequent)**: 빈발이면서 직속 상위 집합(immediate superset) 모두 비빈발. 가장 압축적이나 부분집합의 support 정보 상실
- **닫힌(closed)**: 직속 상위집합 중 support 같은 것이 하나도 없음. **closed frequent** = closed + $s \geq minsup$. support 정보 손실 없이 모든 빈발 집합의 σ 복원 가능
- 관계: **maximal frequent ⊆ closed frequent ⊆ frequent** (maximal은 상위집합이 비빈발이라 support 같을 수 없으므로 항상 closed)

C8. FP-Growth

- 생성-검사(generate-and-test) 미사용. 데이터를 **FP-tree**로 압축, 트리에서 빈발 항목집합 직접 추출 → **후보 생성 없음**
- **구성 단계** 1. 1차 스캔: 항목별 support count, 비빈발 항목 제거 2. 각 거래 내 항목을 **support 내림차순** 정렬 3. 2차 스캔: 거래를 null 루트에서 시작하는 경로로 삽입. **공유 접두사(prefix)는 기존 노드 재사용, count +1** → 압축 4. 같은 항목 노드끼리 포인터(node-link) 연결, 헤더 테이블(header table)에서 항목별 첫 노드 접근
- **교재 예 (Fig. 5.24, 10건, minsup count 2)**: {a,b} {b,c,d} {a,c,d,e} {a,d,e} {a,b,c} {a,b,c,d} {a} {a,b,c} {a,b,d} {b,c,e}. 빈도 a 8 > b 7 > c 6 > d 5 > e 3. 완성 트리 루트 자식 a:8, b:2
- 오름차순 정렬이면 루트 분기 2→5로 트리 비대(Fig. 5.25)
- **빈발 집합 생성 (접미사 기반 분할정복, suffix-based divide-and-conquer)**: e→d→c→b→a 순(bottom-up) 1. node-link로 e 포함 경로 수집 = 접두경로(prefix paths) = **조건부 패턴 베이스(conditional pattern base)** 2. e count 합 3 ≥ 2 → {e} 빈발 3. **조건부 FP-tree** 구성: 경로 count를 e 포함 거래 수로 갱신(예 null→b:2→c:2→e:1의 b,c를 1로), e 노드 제거, 비빈발 항목 제거(b: 1회) 4. 조건부 트리에서 de, ce, ae 하위문제 재귀. 결과: {d,e}=2, {a,d,e}, {c,e}, {a,e}
- 하위문제 서로소(disjoint) → 중복 없음
- **장점**: 데이터 스캔 2회, 후보 생성 없음, 일부 데이터에서 Apriori보다 수 자릿수(orders of magnitude) 빠름
- **단점**: 성능이 압축률(compaction factor)에 의존. 공유 접두사 적으면 포인터·카운터 탓에 원본보다 큼, 메모리 적재 필요. 조건부 트리가 무성(bushy)하면 하위문제 폭증으로 급감

C9. 평가 척도 (Interestingness Measures)

2×2 분할표(contingency table, Table 5.6): f_{11}=A·B 둘 다, f_{10}=A만, f_{01}=B만, f_{00}=둘 다 없음. $f_{1+} = \sigma(A)$, $f_{+1} = \sigma(B)$, 합계 N

- **support–confidence 한계**: support는 저빈도 유용 패턴 제거, confidence는 후건 support $s(Y)$ 무시
- **Tea→Coffee (Table 5.7, 1000명)**: Tea∧Coffee 150, Tea∧¬Coffee 50 (Tea 200), ¬Tea∧Coffee 650, ¬Tea∧¬Coffee 150. Coffee 합 800
  - $s = 0.15$, $c = 150/200 = 0.75$로 높아 보임. 그러나 $P(\text{Coffee}) = 0.8 > 0.75$ → 차 마시면 커피 확률 오히려 감소, 오해 유발 규칙
  - 대조 Tea→Honey: $c = 0.5$로 기각되나 $P(\text{Honey}) = 0.12$ → 12%→50% 상승, 잘못된 기각
  - 해법: 독립 기준선 $s(A)s(B)$와 비교

척도별 식 · 범위·해석 · [Tea-Coffee / Tea-Honey 값]

- **lift = interest factor** I: >1 양, =1 독립, <1 음 · **[$0.15/(0.2 \times 0.8) = 0.9375$ / 4.1667]**
  - $\frac{c(A \to B)}{s(B)} = \frac{s(A,B)}{s(A)s(B)} = \frac{N f_{11}}{f_{1+} f_{+1}}$
- **PS (Piatetsky-Shapiro)**: 0 독립, ± 방향
  - $s(A, B) - s(A)s(B)$
- **φ 계수(상관)**: $[-1, 1]$, PS 정규화판 · **[−0.0625 / 0.5847]**
  - $\frac{f_{11} f_{00} - f_{01} f_{10}}{\sqrt{f_{1+} f_{+1} f_{0+} f_{+0}}} = \frac{s(A,B) - s(A)s(B)}{\sqrt{s(A)(1-s(A))s(B)(1-s(B))}}$
- **IS = cosine**: $[0, 1]$, I와 support의 기하평균, 같은 I면 고support 선호 · **[0.375 / 0.6455]**
  - $\sqrt{I \cdot s(A,B)} = \frac{s(A,B)}{\sqrt{s(A)s(B)}} = \frac{f_{11}}{\sqrt{f_{1+} f_{+1}}}$
- **null-invariance (null addition 불변)**: f_{00}(둘 다 없는 거래)만 늘려도 값 불변. IS 불변, lift·PS·odds ratio·φ는 변함. 예 Table 5.14: f_{00} 100→1100이면 ($f_{11} = 700$, $f_{10} = f_{01} = 100$) IS 0.875 유지, lift 1.094→2.188(교재 본문 0.972→1.944는 계산과 불일치), odds ratio 7→77. 희소 장바구니 데이터에 null-invariant 척도 적합
- **대칭(symmetric)**: $M(A, B) = M(B, A)$ (lift, φ, IS). **비대칭(asymmetric)**: 순서 의존 (confidence). 규칙에는 비대칭 척도가 자연스러움
- **Simpson's paradox**: 숨은 교란변수(confounding variable) 탓에 층화(stratification)하면 관계가 사라지거나 역전. 예: HDTV→운동기구 c 55% vs 45%, 고객층으로 나누면 역전

시험 직전 체크

- $s = \sigma(X \cup Y)/N$, $c = \sigma(X \cup Y)/\sigma(X)$, lift $= c/s(Y)$. {Milk,Diapers}→{Beer}: 0.4, 0.67
- Apriori: 부분집합 빈발 원리(anti-monotone)로 가지치기, $F_{k-1} \times F_{k-1}$ 앞 k-2개 동일 병합, 41→13 (68%↓), 항목 늘면 2^d로 후보 폭증 + 반복 스캔
- FP-Growth: 2회 스캔, 내림차순 정렬로 공유 접두사 압축, 조건부 패턴 베이스→조건부 FP-tree 재귀, 후보 생성 없음. 약점은 메모리·낮은 압축률
- maximal ⊆ closed ⊆ frequent. Tea→Coffee: c 0.75 < P(Coffee) 0.8, lift 0.9375

분류 · 결정트리 · kNN

B1. 결정 트리 구축 (Hunt's algorithm)

- 루트에 전체 훈련 데이터 → 노드에 클래스 2개 이상이면 분할 기준(splitting criterion)으로 속성 테스트 선택 → 결과별 자식 생성 → 재귀. 전부 같은 클래스면 확장 중단, 리프 = 다수 클래스(majority class)
- 예외: 빈 자식 → 부모의 다수 클래스로 리프 / 속성값 동일·클래스 상이 → 확장 불가, 다수 클래스로 리프
- 탐욕적(greedy)·하향식(top-down) 재귀 분할. 설계 쟁점 2개 = 분할 기준 + 정지 기준(stopping criterion)
- 기본 정지: 모든 인스턴스 동일 클래스 or 동일 속성값. 조기 종료(early termination) = 그 전에 멈춤 → B4

속성 유형	분할 방식
이진(binary)	2갈래
명목(nominal)	다중 분할(multiway, 값 개수만큼) or 이진 분할(값 그룹화, k값 → $2^{k-1} - 1$가지)
서열(ordinal)	다중 or 이진. 이진 그룹화 시 순서 보존 필수
연속(continuous)	$A \leq \tau$ 이진 비교 or 구간 이산화(다중). 정렬 후 인접값 중점을 후보 분할점으로 사용

- 연속 속성 최적 τ: 단순 탐색 $O(N^2)$ → 정렬 $O(N \log N)$ 후 본포 갱신 $O(1)$씩 → 전체 $O(N \log N)$. 클래스가 바뀌는 인접 쌍 사이만 후보로 두면 더 감소

- 교재 예(Annual Income): $\tau = 55K$ → $0 \times 0 + 1 \times 0.420 = 0.420$, $\tau = 65K$ → 0.400, 최적 $\tau = 97.5K$ (Gini 0.300)

B2. 불순도 척도 (impurity)

$p_i(t)$ = 노드 t에서 클래스 i 비율, c = 클래스 수

- Entropy $= -\sum_{i=0}^{c-1} p_i(t) \log_2 p_i(t)$ $(0 \log_2 0 = 0)$
- Gini $= 1 - \sum_i p_i(t)^2$
- Classification error $= 1 - \max_i p_i(t)$
- 단일 클래스면 0, 균등 분포면 최대. **2클래스 최대: Gini 0.5 / Entropy 1 / Error 0.5** ($p = 0.5$). c클래스 최대: Gini $1 - 1/c$, Entropy $\log_2 c$
- 세 척도는 순서가 일관됨. 척도 선택보다 가지치기 전략이 최종 트리에 더 큰 영향(교재 9번 특징)

노드 (C0, C1)	Gini	Entropy	Error
N1 (0, 6)	0	0	0
N2 (1, 5)	0.278	0.650	0.167
N3 (3, 3)	0.5	1	0.5

이득(gain): $\Delta = I(\text{parent}) - I(\text{children})$, $I(\text{children}) = \sum_j \frac{N(v_j)}{N} I(v_j)$. 최대 이득 = 자식 가중 불순도 최소. Entropy 기반이면 정보 이득(information gain) Δ_{info}

교재 대출 데이터(Yes 3, No 7, $N = 10$):

- Entropy: 부모 0.881. Home Owner: yes(0/3)=0, no(3/7)=0.985 → $\frac{3}{10} \cdot 0 + \frac{7}{10} \cdot 0.985 = 0.690$, $\Delta = 0.191$. Marital Status: Single(2/5)=0.971, Married(0/3)=0, Divorced(1/2)=1 → 0.686, $\Delta = 0.195$ → Marital Status 선택
- Gini(이진 분할): 부모 $1 - 0.3^2 - 0.7^2 = 0.420$. Home Owner: N1=0, N2=0.490 → $(3/10) \cdot 0 + (7/10) \cdot 0.490 = 0.343$, gain $0.420 - 0.343 = 0.077$
- Marital 이진 분할 3가지: {Married} vs {Single,Divorced} = 0.343 / {Single} vs {Married,Divorced} = 0.400 / {Divorced} vs {Single,Married} = 0.400 → Home Owner와 {Married} 분할이 최선(0.343)

이득 비율(gain ratio, C4.5): 불순도 척도는 값 종류 많은 속성(다중 분할)을 선호하는 편향 보유. 예: Customer ID → 자식 전부 순수(불순도 0)지만 새 데이터에 일반화 불가, 과적합 위험

- Gain ratio $= \frac{\Delta_{info}}{\text{Split Info}}$, Split Info $= -\sum_{i=1}^{k} \frac{N(v_i)}{N} \log_2 \frac{N(v_i)}{N}$
- 균등 k분할이면 Split Info $= \log_2 k$ → 분할 수 많을수록 커져 gain ratio 감소. 대안: CART처럼 이진 분할만 사용
- 교재 예 3.4 (20건, 10:10, 부모 Entropy 1): Gender → 자식 0.971, GR $= 0.029/1 = 0.029$ / Car Type(4·8·8) → 자식 0.380, GR $= 0.620/1.52 = 0.41$ / Customer ID(20분할) → 자식 0, GR $= 1/4.32 = 0.23$ ⇒ 정보 이득 최대는 Customer ID지만 gain ratio 최대는 **Car Type**

B3. 결정 트리 특징

- 비모수(nonparametric): 분포 가정 불필요, 범주·연속 모두 변환 없이 처리, 다중 클래스 직접 처리
- 작은 트리는 해석 쉬움. 예측 최악 $O(w)$ (w=최대 깊이)로 빠름. 최적 트리 탐색은 어려워 탐욕적 휴리스틱 사용
- 이산 함수의 보편 표현(universal representation)
- 결측값 처리: C4.5 확률적 분할(probabilistic split), CART 대리 분할(surrogate split)
- 상호작용 속성(XOR 등): 탐욕적 선택이라 놓치기 쉬움 → 트리 복잡화
- 불필요 속성(irrelevant): 이득이 작아 거의 선택 안 됨 → 소수면 강건. 다수면 우연히 선택될 위험
- 중복 속성(redundant): 하나만 선택되고 나머지는 미사용 → 영향 적음
- 직선형 분할(rectilinear): 결정 경계가 축에 평행 → 대각선 경계 표현에 약함(사선 분할 oblique tree로 보완)
- 데이터 단편화(data fragmentation): 깊어질수록 노드당 인스턴스 감소 → 통계적 근거 부족. 노드 인스턴스 수 임계값 미만이면 분할 금지로 대응

B4. 과적합과 가지치기 ★최우선

과소적합(underfitting): 트리가 너무 단순 → 훈련·테스트 오차 둘 다 큼 **과적합(overfitting)**: 훈련 오차는 계속 0까지 감소, 테스트(일반화) 오차는 어느 크기 이후 다시 증가 → 두 오차 간격 확대. 훈련 오차가 일반화 오차를 과소 추정

- 교재 예 3.5: 2차원 데이터, 10% 훈련 → 리프 1~8까지 두 오차 함께 감소, 이후 150까지 훈련 오차만 계속 감소
- 모델 복잡도(model complexity) = 추정할 파라미터 수 ≈ 내부 노드 테스트 조건 수(리프 수)

과적합 원인	내용
훈련 데이터 부족 (limited training size)	유한 표본이 전체 패턴을 대표하지 못함. 훈련 2배(20%) → 오차 간격 축소 (예 3.6)
높은 모델 복잡도(high model complexity)	조합 수 많을수록 우연히 좋은 조합 선택 → 다중 비교 문제(multiple comparison)
노이즈(noise)	잡음 인스턴스까지 맞추는 경계 학습 (예 3.5의 균등분포 + 400개)

- 다중 비교 예: 무작위 예측자가 10일 중 9일 이상 적중 확률 $\frac{\binom{10}{9} + \binom{10}{10}}{2^{10}} = 0.0107$, 분석가 200명 중 1명 이상 적중 확률 $1 - (1 - 0.0107)^{200} = 0.8847$ → 속성 100개 무관 속성 추가 시 테스트 오차 개선 없음(예 3.7)

일반화 오차 추정 (모델 선택, 3.5)

1. **검증셋(validation set)**: D.train → D.tr(2/3) + D.val(1/3). err_{val} 최소 모델 선택. 분할 크기에 민감 (D.tr 작으면 모델 부실, D.val 작으면 추정 불안정). 예 3.8: $err_{val}(T_L) = 6/16 = 0.375$, $err_{val}(T_R) = 4/16 = 0.25$ → T_R 선택
2. **모델 복잡도 반영**: 오컴의 면도날(Occam's razor, 간결성 원리) — 오차 같으면 단순 모델. $gen.error(m) = train.error(m) + \alpha \times complexity(M)$, α는 검증셋으로 선택 (AIC·BIC·SRM과 같은 계열)
3. **비관적 오차 추정(pessimistic error estimate)**: 트리 복잡도 = k/N_{train} (k=리프 수) - $err_{gen}(T) = err(T) + \Omega \times \frac{k}{N_{train}}$ (= 1판 형태 $e'(T) = \frac{e(T) + \Omega \cdot k}{N}$, $e(T)$=훈련 오분류 수) - Ω = 리프 1개 추가 비용(훈련 오류 1개 대비 상대 비용). 낙관적 추정(optimistic, resubstitution) = 훈련 오차 그대로 사용 - **예 3.9** ($N = 24$): T_L 리프 7·오류 4, T_R 리프 4·오류 6. 훈련 오차 T_L 0.167 < T_R 0.25
   - $\Omega = 0.5$: $T_L = (4 + 0.5 \cdot 7)/24 = 7.5/24 = 0.3125$, $T_R = (6 + 0.5 \cdot 4)/24 = 8/24 = 0.3333$ → T_L **선택**
   - $\Omega = 1$: $T_L = 11/24 = 0.458$, $T_R = 10/24 = 0.417$ → T_R **선택**
   - $\Omega = 0.5$의 뜻: 훈련 인스턴스 1개라도 더 맞히면 노드를 두 자식으로 항상 확장. Ω는 검증셋으로 결정
   - 1판 표준 예: 리프 30, 오류 10, $N = 1000$ → 훈련 1%, 비관적 $(10 + 30 \times 0.5)/1000 = 2.5\%$
   - 1판 표준 예(subtree replacement): 부모 Yes20/No10 → $(10 + 0.5)/30 = 10.5/30$. 4분할 (8/4, 3/4, 4/1, 5/1) → 오류 9, $(9 + 4 \times 0.5)/30 = 11/30$ → 분할 후가 더 큼 → **가지치기 (PRUNE)**
4. **최소 기술 길이(MDL)**: $Cost(model, data) = Cost(data|model) + \alpha \times Cost(model)$ (오분류 인코딩 비트 + 모델 인코딩 비트). 총 길이 작은 모델 선택
5. **통계적 상한(statistical bounds)**: 리프 오류를 이항분포 → 정규근사 상한 $e_{upper}(N, e, \alpha)$. 예 3.10($\alpha = 25\%$): 분할 전 $e_{upper}(7, 2/7) = 0.503 \rightarrow 7 \times 0.503 = 3.521$ 오류. 분할 후 $e_{upper}(4, 1/4) = 0.537$, $e_{upper}(3, 1/3) = 0.650 \rightarrow 4 \times 0.537 + 3 \times 0.650 = 4.098 > 3.521$ → **분할 안 함**

사전 vs 사후 가지치기 (3.5.4)

	사전 가지치기 (prepruning, early stopping rule)	사후 가지치기(post-pruning)
방식	완전 성장 전에 중단. 일반화 오차 추정치 개선이 임계값 미만이면 확장 중지	최대로 키운 뒤 상향식(bottom-up) 절단. 일반화 오차가 줄면 대체, 더 이상 개선 없으면 종료
조건/연산	인스턴스 수 < 임계값, 클래스 분포가 속성과 독립(χ^2 검정), 불순도 개선 없음(슬라이드), 비관적 오차·검증 오차 ·통계 상한 개선 미만	subtree replacement: 서브트리 → 다수 클래스 리프. subtree raising: 서브트리 → 가장 많이 쓰인 가지로 끌어올림
장점	과적합 서브트리 생성 계산 절약	전체 트리 보고 판단 → 대체로 더 좋은 결과
단점	지금 이득 없어도 다음 분할에서 좋아질 수 있는데 놓침(편향의 특성, 조기 종료)	다 키운 뒤 잘라낸 부분의 계산 낭비

- 교재 웹 로봇 예(그림 3.32): depth=1 서브트리 → raising, depth>1 & MultiAgent=0 → replacement(클래스 0 리프)
- C4.5rules(슬라이드): 규칙에서 조건 1개씩 뺀 r'와 비관적 오차 비교 → 낮으면 prune

B5. 모델 평가 (3.2, 3.6)

	예측 +	예측 −
실제 +	f_{11} (TP)	f_{10} (FN)
실제 −	f_{01} (FP)	f_{00} (TN)

- Accuracy $= \frac{f_{11} + f_{00}}{f_{11} + f_{10} + f_{01} + f_{00}}$, Error rate $= \frac{f_{10} + f_{01}}{\text{전체}} = 1 - \text{Accuracy}$
- 홀드아웃(holdout): D → D.train/D.test(예 2/3·1/3). 훈련 작으면 편향, 테스트 작으면 신뢰도 낮음, 분할에 따라 분산 큼. 반복 → 무작위 부표집(random subsampling)
- k-겹 교차검증(k-fold CV): k등분, 각 fold 한 번씩 테스트, $err_{test} = \sum_i err_{sum}(i)/N$. 각 인스턴스 테스트 1회·훈련 $k-1$회. k 작으면 일반화 오차 과대 추정, 실무 $k = 5 \sim 10$. 층화 교차검증(stratified CV)으로 클래스 비율 유지
- LOOCV(leave-one-out): $k = N$. 훈련 데이터 최대 활용, 대신 N번 학습으로 계산 비용 큼, 특수 상황에서 오도 가능

B6. kNN 분류 (k-nearest neighbor)

- 필요 요소: 저장된 훈련 레코드, 거리 척도, k
- 단계: ① 테스트 레코드와 모든 훈련 레코드 거리 계산(유클리드 $d(p, q) = \sqrt{\sum_i (p_i - q_i)^2}$) ② 가장 가까운 k개 선택 ③ 다수결 투표(majority vote)로 클래스 결정
- 거리 가중 투표: $w = 1/d^2$ → 가까운 이웃 영향 확대, k 선택 민감도 완화
- k 선택: 너무 작으면 노이즈에 민감 / 너무 크면 다른 클래스 점까지 이웃에 포함. 2클래스는 홀수 k로 동점 방지
- 속성 스케일링(scaling): 범위 큰 속성이 거리 지배(키 1.5–1.8m vs 몸무게 90–300lb vs 소득 $10K$–1M) → 정규화 필수
- 차원의 저주(curse of dimensionality): 고차원에서 거리 차이 희미 → 직관에 반하는 결과. 슬라이드 예: 111…10 vs 011…11, 100…00 vs 000…01 둘 다 $d = 1.4142$ → 단위 길이 정규화로 해결
- 게으른 학습기(lazy learner): 명시적 모델 없음(결정 트리·규칙 기반 = eager learner와 대비) → 학습 비용 거의 0, 예측 비용 큼(매번 전체 거리 계산)
- 1-NN 결정 경계 = 보로노이 다이어그램(Voronoi diagram). 임의 모양 결정 경계 가능(유연), 국소 정보 기반이라 k 작을 때 노이즈 취약
- 인스턴스 기반(instance-based) 분류기. 극단 = 암기 학습기(rote-learner, 정확히 일치할 때만 분류). PEBLS: 명목 속성 MVDM 거리, $k = 1$

손계산 예: 훈련 A(1,1)+, B(2,1)+, E(2,3.5)−, C(4,4)−, D(5,4)−, 질의 q(2,2)

점	d^2	d	$w = 1/d^2$
B +	1	1	1
A +	2	1.414	0.5
E −	2.25	1.5	0.444
C −	8	2.828	0.125
D −	13	3.606	0.077

- $k = 1$: B → **+** / $k = 3$: B,A,E → 2:1 → **+** / $k = 5$ 다수결: 2:3 → **−**
- $k = 5$ 가중: $+ = 1 + 0.5 = 1.5$, $- = 0.444 + 0.125 + 0.077 = 0.646$ → **+** (가중 투표가 k 과대 효과 보정)

시험 직전 체크

- 2클래스 최대 불순도 Gini 0.5 / Entropy 1 / Error 0.5. 이득 = 부모 − 자식 가중평균, gain ratio = 이득 / Split Info(다중 분할 편향 보정)
- 비관적 오차 $err(T) + \Omega k/N$: 예 3.9 $\Omega = 0.5 \rightarrow T_L$ (0.3125<0.3333), $\Omega = 1 \rightarrow T_R$(0.417<0.458). 분할 후 추정 오차가 크면 가지치기
- 사전 = 조기 정지(계산 절약, 조기 종료 위험) / 사후 = 다 키운 뒤 replacement·raising(결과 우수, 계산 낭비)
- 과적합: 훈련 오차↓·테스트 오차↑, 원인 = 데이터 부족·복잡도·다중 비교·노이즈
- kNN: k 작으면 노이즈 민감, 크면 타 클래스 혼입, $w = 1/d^2$, 스케일링 필수, lazy, 1-NN = Voronoi

군집분석

D. 군집분석 (Cluster Analysis, 7장)

D1. 군집 유형 (Types of Clusterings)

- **분할(partitional)**: 겹치지 않는 부분집합으로 나눔 / **계층(hierarchical)**: 중첩된 군집의 트리(덴드로그램)
- **배타(exclusive)**: 한 점은 한 군집만 / **중첩(overlapping)**: 여러 군집 동시 소속 / **퍼지(fuzzy)**: 소속 가중치 0~1, 합 1
- **완전(complete)**: 모든 점 할당 / **부분(partial)**: 노이즈·이상치는 미할당

D2. 군집 종류 (Types of Clusters)

- **Well-separated**: 군집 내 모든 점이 군집 밖 어느 점보다 서로 가까움
- **Prototype(center)-based**: 자기 군집 원형(centroid/medoid)에 더 가까움 → 구형 군집
- **Graph-based(contiguity)**: 연결된 성분, 이웃끼리 연결 → 사슬 모양 가능
- **Density-based**: 저밀도 영역으로 분리된 고밀도 영역 → 불규칙 모양·노이즈 처리
- **Shared-property(conceptual)**: 공통 성질 공유 군집

D3. K-means ★최우선

기본 알고리즘 (Algorithm 7.1)

1. 초기 중심(centroid) K개 선택
2. 각 점을 가장 가까운 중심에 할당 → K개 군집 형성
3. 각 군집의 중심을 재계산
4. 2~3을 반복
5. 중심 변화 없을 때(또는 변화 소수) 종료

근접도·중심·목적함수 (Table 7.2)

근접도 함수	중심	목적함수
맨해튼 (L1)	중앙값 (median)	점–중심 L1 거리 합 최소화
제곱 유클리드 (L_2^2)	평균(mean)	점–중심 제곱 L2 거리 합 최소화 (SSE)
코사인 (cosine)	평균(mean)	점–중심 코사인 유사도 합 **최대화**
브레그만 발산 (Bregman divergence)	평균(mean)	점–중심 브레그만 발산 합 최소화

- 문서 데이터 → 코사인, 유클리드 데이터 → 유클리드 주로 사용
- **SSE (Sum of Squared Error)**: $SSE = \sum_{i=1}^{K} \sum_{x \in C_i} dist(c_i, x)^2$, 중심 $c_i = \frac{1}{m_i} \sum_{x \in C_i} x$
- **평균이 SSE 최소화하는 이유**: $\frac{\partial}{\partial c_k} \sum_{x \in C_k} (c_k - x)^2 = \sum 2(c_k - x) = 0 \Rightarrow c_k = \frac{1}{m_k} \sum x$ (L1 할 최소 → 중앙값)
- **수렴**: 할당·갱신 단계 모두 SSE 비증가 → 반드시 수렴, 단 **국소 최적(local minimum)**만 보장, 전역 최적 보장 없음
- 대부분 수렴은 초기 몇 번 반복에서 발생 → "중심 변화 1% 미만" 같은 약한 종료 조건 사용

초기 중심 선택 (Choosing Initial Centroids)

- 무작위 초기화 → 결과 불안정, 나쁜 국소 최적 위험
- **여러 번 무작위 실행 후 SSE 최소 결과 선택** → K 크면 효과 적음 (모든 군집에 중심 하나씩 들어갈 확률 낮음)
- **계층 군집으로 초기화**: 표본 추출 → 계층 군집 → K개 군집 중심 사용 (표본 작고 K 작을 때)
- **최원점 방식**: 첫 중심 무작위, 이후 기존 중심에서 가장 먼 점 선택 → 이상치 선택 위험
- **K-means++ (Algorithm 7.2)**: 첫 중심 무작위 → 각 점의 최근접 중심 거리 $d(x)$ 계산 → 다음 중심을 확률 $\propto d(x)^2$ 로 선택 → K개까지 반복. SSE 측면 최적해 대비 $O(\log k)$ 근사 보장, 이상치 영향 완화
- **Bisecting K-means**로 초기화도 가능

보완 이슈

- **빈 군집 (empty cluster)**: SSE에 가장 크게 기여하는 점 또는 SSE 가장 큰 군집에서 점을 뽑아 대체 중심으로 지정
- **이상치 (outlier)**: 평균 기반 → 중심을 끌어당김, SSE 증가 → 사전에 이상치 제거 또는 후처리로 작은 군집 제거
- **후처리 (postprocessing)로 SSE 감소**
- 군집 수 증가: SSE 큰 군집 **분할(split)**, 모든 중심에서 먼 점으로 **새 중심 도입**
- 군집 수 감소: 중심 **분산(disperse)** → 그 군집 점 재할당, SSE 증가 최소인 두 군집 **병합(merge)**
- **점진적 업데이트 (incremental update)**: 점 하나 할당할 때마다 중심 갱신 → 빈 군집 없음, 가중치 조정 가능, 단 **순서 의존성** 발생·계산 비용 약간 증가

Bisecting K-means (Algorithm 7.3)

1. 전체를 하나의 군집으로 시작
2. 분할할 군집 선택 (가장 큰 군집 또는 SSE 가장 큰 군집)
3. 그 군집을 2-means로 여러 번 시험 분할 → SSE 최소 분할 채택
4. 군집 수 K 될 때까지 반복 - 초기화 문제에 덜 민감, 계층 구조 결과도 산출 → 최종 중심으로 기본 K-means 한 번 더 돌려 정제 가능

한계 (Limitations)

- 군집 **크기·밀도가 다르거나 비구형(non-globular)**이면 자연 군집 탐지 실패
- **이상치에 민감**
- 평균 정의 가능한 데이터에만 적용 (아니면 K-medoid)
- 대안: K를 크게 잡아 잘게 나눈 뒤 병합

복잡도: 시간 $O(I \cdot K \cdot m \cdot n)$ (I 반복, K 군집, m 점, n 속성) → m에 선형, 공간 $O((m + K)n)$

손계산 예 (1차원, K=2): 점 {1, 2, 4, 7, 9, 10}, 초기 중심 $c_1 = 1, c_2 = 4$

- **반복 1**: 할당 C1={1,2}, C2={4,7,9,10} → 중심 $c_1 = 1.5$, $c_2 = 30/4 = 7.5$
- SSE = (0.25+0.25) + (12.25+0.25+2.25+6.25) = 0.5 + 21 = **21.5**
- **반복 2**: 4 → |4−1.5|=2.5 < |4−7.5|=3.5 이므로 C1로 이동. C1={1,2,4}, C2={7,9,10} → $c_1 = 7/3 \approx 2.33$, $c_2 = 26/3 \approx 8.67$
- SSE = (1.78+0.11+2.78) + (2.78+0.11+1.78) = 4.67 + 4.67 = **9.33** (=28/3)
- **반복 3**: 할당 변화 없음 (4: 1.67 vs 4.67, 7: 4.67 vs 1.67) → **수렴**, SSE 21.5 → 9.33 감소 확인

D4. 계층 군집 (Agglomerative Hierarchical Clustering)

기본 알고리즘 (Algorithm 7.4): 근접도 행렬 계산 → 반복 {가장 가까운 두 군집 병합 → 근접도 행렬 갱신} → 군집 하나 남으면 종료

- 결과를 **덴드로그램(dendrogram)**으로 표시, 병합 높이 = 병합 시점 군집 간 거리
- 병합 결정은 되돌릴 수 없음(국소 판단), 전역 목적함수 없음
- **복잡도**: 공간 $O(m^2)$, 시간 $O(m^3)$ (힙 등 사용 시 $O(m^2 \log m)$)

근접도 정의	식	특징
MIN (single link)	$\min_{x \in A, y \in B} d(x, y)$	비구형·길쭉한 군집 잘 잡음, 노이즈·이상치 민감, **chaining** 현상
MAX (complete link, CLIQUE)	$\max_{x \in A, y \in B} d(x, y)$	노이즈에 덜 민감, **큰 군집 쪼갬**, 구형 군집 편향
Group average	$\frac{\sum_{x \in A} \sum_{y \in B} d(x,y)}{m_A \cdot m_B}$	MIN·MAX 절충, 노이즈 덜 민감, 구형 편향
Ward	병합 시 SSE **증가량**	K-means의 계층 버전, 구형 편향, K-means 초기화에 활용
Centroid	두 군집 중심 간 거리	**역전(inversion)** 가능: 나중 병합 거리가 더 작을 수 있음

교재 6점 예 (Table 7.4 거리행렬)

- 핵심 거리: d(3,6)=0.11, d(2,5)=0.14, d(3,4)=0.15, d(2,3)=0.15, d(6,4)=0.22, d(1,3)=0.22
- **Single**: {3,6} 0.11 → {2,5} 0.14 → dist({3,6},{2,5}) = min(0.15,0.25,0.28,0.39) = **0.15**, {4}도 0.15로 합류 → 마지막 {1} 0.22
- **Complete**: {3,6} 0.11 → {2,5} 0.14 → {3,6}+{4}: max(0.15,0.22)=**0.22** ({2,5}와는 max=0.39, {1}과는 0.23이라 {4} 선택) → {2,5}+{1} 0.34 → 전체 0.39
- **Group average**: dist({3,6,4},{1}) = (0.22+0.37+0.23)/(3×1) = 0.28, dist({2,5},{1}) = (0.24+0.34)/(2×1) = 0.29, dist({3,6,4},{2,5}) = (0.15+0.28+0.25+0.39+0.20+0.29)/(3×2) = **0.26** → 4단계에 {3,6,4}와 {2,5} 병합

D5. DBSCAN (밀도 기반)

- 밀도 = 반경 **Eps** 안 점의 수 (자기 자신 포함)
- **핵심점(core point)**: Eps 이내에 점 **MinPts개 이상**
- **경계점(border point)**: 핵심점 아님, 단 어떤 핵심점의 Eps 이웃 안에 위치
- **노이즈점(noise point)**: 핵심점도 경계점도 아님
- **알고리즘 (Algorithm 7.5)**: ① 모든 점을 core/border/noise로 표시 ② 노이즈 제거 ③ Eps 이내 핵심점끼리 간선 연결 ④ 연결된 핵심점 묶음 → 각각 하나의 군집 ⑤ 경계점을 연관 핵심점의 군집에 할당
- **장점**: 군집 수 미리 지정 불필요, 임의 모양·크기 군집 탐지, 노이즈에 강건
- **단점**: **밀도가 다양한 군집**에 약함, 고차원 데이터에서 밀도 정의 곤란, 근접도 계산 비용
- **복잡도**: 시간 최악 $O(m^2)$ (저차원+kd-tree 시 $O(m \log m)$), 공간 $O(m)$
- **Eps 정하기 (k-dist 그래프)**: 각 점의 k번째 최근접 이웃 거리(k-dist)를 오름차순 정렬해 그림 → 급격히 꺾이는 지점 값을 Eps로, k를 MinPts로 (교재 기본 MinPts=4)

D6. 군집 평가 (Cluster Validity)

비지도 지표 (unsupervised, internal)

- **응집도(cohesion)** = $SSE = \sum_i \sum_{x \in C_i} dist(c_i, x)^2$ (작을수록 좋음)
- **분리도(separation)** = $SSB = \sum_i m_i \, dist(c_i, c)^2$ (c = 전체 평균, 클수록 좋음)
- $TSS = SSE + SSB$ (TSS 일정 → SSE 최소화 ⇔ SSB 최대화)
- **실루엣 계수 (silhouette coefficient)**: 점 i에 대해
- a_i = 같은 군집 다른 점들과의 평균 거리
- b_i = 다른 군집 각각과의 평균 거리 중 최솟값
- $s_i = \frac{b_i - a_i}{\max(a_i, b_i)}$, 범위 $[-1, 1]$, 1에 가까울수록 좋음, 음수 = 잘못 할당 의심 ($a_i > b_i$)
- 군집·전체 실루엣 = 점들의 평균
- **근접도 행렬 상관**: 실제 근접도 행렬 vs 이상적 유사도 행렬(같은 군집 1, 다르면 0) 간 상관 → 높을수록 좋음, 정렬된 유사도 행렬 시각화도 활용
- **CPCC (cophenetic correlation)**: 계층 군집 평가, 덴드로그램 병합 거리와 원래 거리의 상관

지도 지표 (supervised, external)

- **엔트로피(entropy)**: 각 군집 안 클래스 분포의 엔트로피, 낮을수록 좋음
- **순도(purity)**: 군집별 최다 클래스 비율 가중합, 높을수록 좋음
- 기타: precision, recall, F-measure, Rand 통계량, Jaccard 계수

군집 수 정하기: K별 SSE 그래프에서 **꺾이는 점 (knee/elbow)** 선택, 평균 실루엣 계수의 봉우리도 참고

시험 직전 체크

- K-means 5단계 + "평균 = SSE 최소, 중앙값 = L1 최소" + 국소 최적만 보장
- 초기화 해법: 여러 번 실행, K-means++($\propto d^2$), 계층 군집 표본, Bisecting
- 한계: 크기·밀도 차이, 비구형, 이상치 / 복잡도 $O(IKmn)$ vs 계층 $O(m^2)$ 공간·$O(m^3)$ 시간
- MIN = chaining·비구형 OK, MAX = 큰 군집 쪼갬, DBSCAN = 밀도 다양하면 실패
- 실루엣 $s = (b - a)/\max(a, b) \in [-1, 1]$, $TSS = SSE + SSB$